

Khung Đa Phương Thức Nhận Thức Ngữ Cảnh cho Dự Đoán Mức Độ Stress Liên Tục

[Họ và tên sinh viên]

[Khoa/Trường]

GVHD: [Tên giảng viên hướng dẫn]

[Ngày bảo vệ]

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

Nội dung trình bày

- 1 Đặt vấn đề và mục tiêu nghiên cứu
- 2 Phương pháp đề xuất
- 3 Thực nghiệm và kết quả
- 4 Đóng góp, hạn chế và hướng phát triển
- 5 Kết luận

Thông điệp chính của khóa luận

Bài toán không chỉ là dự đoán stress, mà là diễn giải stress theo ngữ cảnh.

$$R^2 = 0.956$$

Kết quả tốt nhất
trong thiết lập
semi-synthetic

Context-aware

Phân biệt HR cao
do vận động và
HR cao do stress

Heuristic có neo

Công thức rule-based
có cơ sở nghiên cứu,
không phải chẩn đoán

Thông điệp bảo vệ: Kết quả metric được hiểu trong phạm vi bộ dữ liệu bán mô phỏng; đóng góp chính là khung sinh dữ liệu và pipeline context-aware có thể truy vết.

Vấn đề thực tế:

- WHO: đại dịch COVID-19 tăng **25%** rối loạn lo âu và trầm cảm toàn cầu.
- Stress kéo dài gây bệnh tim mạch, suy giảm miễn dịch, trầm cảm.
- Phương pháp đánh giá hiện tại: bảng hỏi hồi cứu — *chủ quan, không liên tục, gây gián đoạn*.

3 khoảng trống cốt lõi:

- ① Phân loại stress rời rạc $\neq$ theo dõi cường độ liên tục
- ② **Nhập nhằng sinh lý**: $HR = 120$ bpm – chạy bộ hay stress cao?
- ③ Chưa khai thác phụ thuộc thời gian dài hạn (tích lũy stress)

Mục tiêu: Dự đoán stress liên tục (1–9) bằng pipeline context-aware có thể giải thích được

Khoảng trống nghiên cứu

Gap	Xu hướng phổ biến	Hướng tiếp cận của khóa luận
G1	Phân loại stress rời rạc	Hồi quy stress liên tục (1–9)
G2	HAR và stress xử lý tách rời	Pipeline thống nhất 4 module với Context-Stress Modifier
G3	So sánh mô hình chưa công bằng	Benchmark 5 kiến trúc trên cùng pipeline
G4	Giải thích kết quả hạn chế	4 phương pháp phân tích đặc trưng + phân tích lỗi đa chiều

Logic nghiên cứu xuyên suốt:

Câu hỏi nghiên cứu → Thiết kế phương pháp →
Bằng chứng thực nghiệm → Kết luận khoa học

Câu hỏi nghiên cứu và giả thuyết

RQ/H	Nội dung	Kiểm chứng bằng
RQ1/H1	Context-aware có giúp diễn giải tín hiệu sinh lý tốt hơn?	Context-Stress Modifier
RQ2/H2	Mô hình chuỗi có vượt mô hình phi chuỗi?	So sánh MLP vs LSTM
RQ3/H3	Bayesian Optimization có tạo khác biệt đáng kể?	Baseline vs Tuned
RQ4/H4	Nhóm đặc trưng nào đóng góp chính?	4 phương pháp FI

Toàn bộ phương pháp và thực nghiệm đều được thiết kế để trả lời trực tiếp 4 câu hỏi này.

Kiến trúc tổng thể hệ thống (4 module)

- ➊ **HAR Module:** nhận dạng 6 hoạt động từ WISDM bằng Stacked Bi-LSTM → 96.19% accuracy.
- ➋ **Data Generation:** sinh 54,448 mẫu đa phương thức có Context-Stress Modifier.
- ➌ **Feature & Pipeline:** 44 trường → **13 đặc trưng**; Split → Encode → Normalize → Sequence (chống leakage).
- ➍ **Model & Evaluation:** huấn luyện, Bayesian tuning, so sánh 5 kiến trúc và giải thích kết quả.

Điểm then chốt: Nhãn hoạt động từ Module 1 là đầu vào bắt buộc cho Module 2 — *tạo nên tính nhận thức ngữ cảnh của toàn hệ thống*

Module 1 — Kết quả HAR trên WISDM v1.1

Mô hình: Stacked Bi-LSTM (2 lớp) trên 1,098,207 bản ghi gia tốc kế, 6 hoạt động.

Kết quả phân loại:

- Accuracy: **96.19%** (vượt mục tiêu 90%)
- Jogging: $F1 = 0.99$
Sitting: $F1 = 0.99$
- Walking: $F1 = 0.96$
Standing: $F1 = 0.98$
- Upstairs / Downstairs: $F1 \approx 0.90\text{--}0.91$

Nhận xét:

- Hoạt động tĩnh và Jogging rất đặc trưng.
- Upstairs/Downstairs tín hiệu tương tự nhưng vẫn $\geq 88\%$.
- Nhãn hoạt động đủ tin cậy làm đầu vào Module 2.

Vai trò: Nhãn hoạt động từ Module 1 là đầu vào bắt buộc của Module 2 — tạo nên tính *nhận thức ngữ cảnh* cho toàn hệ thống

Tạo dữ liệu đa phương thức: 54,448 mẫu

- Mô phỏng lịch trình 30 ngày: home, commute, work, gym, social, outdoor.
- Kết hợp sự kiện đặc biệt (6%/ngày: deadline, ốm, thi cử) + chu kỳ tuần/tháng.
- Tổng hợp 5 nhóm: *sensor*, *temporal*, *physiological*, *behavioral*, *contextual*.
- Tần suất 2 mẫu/phút $\approx 1,815$ mẫu/ngày $\times 30$ ngày = **54,448 mẫu**.

Tại sao dùng dữ liệu bán mô phỏng?

- Kiểm soát biến thực nghiệm có hệ thống
- Kiểm chứng giả thuyết về Context-Stress Modifier
- Dữ liệu gia tốc kế *thực* từ WISDM + hành vi *mô phỏng* có *kiểm soát*

Phạm vi: Nhấn stress và hệ số hành vi là heuristic có neo nghiên cứu, phục vụ kiểm chứng phương pháp, không thay thế nhãn lâm sàng/EMA.

Chi tiết lịch trình mô phỏng trong 1 ngày

Đặt vấn đề và
mục tiêu
nghiên cứuPhương pháp
đề xuấtThực nghiệm
và kết quảĐóng góp, hạn
chế và hướng
phát triển

Kết luận

Khung giờ	Hoạt động chính	Vị trí	Ý nghĩa với stress
06:00–08:00	Thức dậy, sinh hoạt cá nhân	Home	Trạng thái hồi phục
08:00–09:00	Di chuyển đi làm	Commute	Tăng nhẹ do giao thông
09:00–12:00	Làm việc buổi sáng	Work	Áp lực tăng dần
12:00–13:00	Nghỉ trưa	Work/Outdoor	Giảm tạm thời
13:00–17:00	Làm việc buổi chiều	Work	Áp lực cao nhất ngày
17:00–18:00	Di chuyển về nhà	Commute	Chuyển pha stress
18:00–20:00	Ăn tối/tập luyện	Home/Gym	Phục hồi dần
20:00–22:30	Giải trí, nghỉ ngơi	Home	Giảm stress rõ rệt
22:30–06:00	Ngủ	Home	Reset sinh lý ngày hôm sau

- 2 mẫu/phút trong khung thức tạo khoảng **1,815 mẫu/ngày**.
- Mô phỏng 30 ngày tạo **54,448 mẫu**, giữ được cả nhịp ngày và tích lũy theo tuần/tháng.

Nhiều và biến thiên: tránh dữ liệu “quá sạch”

$$S_0(d) = S_{\text{base}} + \eta_{\text{daily}} + \eta_{\text{weekly}} + \eta_{\text{monthly}} + \eta_{\text{event}}$$

- **Life events** xảy ra ngẫu nhiên với xác suất **6%/ngày**, kéo dài 1–4 ngày (deadline, ốm, thi cử, thăm gia đình).
- **Daily noise** trên sleep/mood/energy/workload để phản ánh dao động tự nhiên từng ngày.
- **Chu kỳ tuần**: stress thường tăng dần trong tuần làm việc, cao nhất thứ 5–6, giảm cuối tuần.
- **Chu kỳ tháng**: biến thiên theo chu kỳ 28 ngày.
- Nhiều nhịp tim: $\varepsilon \sim \mathcal{U}(-4, +4)$ bpm.
- Ràng buộc sinh lý: $HR \in [HR_{\text{rest}} - 10, HR_{\text{max}}]$.
- Stress đầu ra luôn clip trong **[1,9]**.

Mục tiêu của nhiều: tạo dữ liệu đủ chân thực để học tổng quát, nhưng vẫn có cấu trúc để kiểm chứng giả thuyết nghiên cứu.

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

Từ WISDM gốc đến tập dữ liệu 44 trường

- ➊ **Nạp WISDM thực:** 1,098,207 bản ghi gia tốc kế, 36 người dùng, 6 hoạt động.
- ➋ **Tạo kho mẫu theo hoạt động:**
Sitting/Standing/Walking/Jogging/Upstairs/Downstairs.
- ➌ **Sinh lịch 30 ngày:** mỗi timestamp có nhãn hoạt động a_t từ ScheduleGenerator.
- ➍ **Wisdmloader ghép dữ liệu:** lấy mẫu gia tốc kế thực phù hợp với a_t và gán vào Accelerometer_X/Y/Z.
- ➎ **Orchestrator hợp nhất:** sensor thực + biến sinh lý/hành vi/ngữ cảnh mô phỏng → 44 trường dữ liệu.

HAR kiểm chứng trên dữ liệu sinh	Jogging	Walking	Upstairs	Trung bình
Accuracy (%)	100.0	80.1	34.4	86.2

Thông điệp: gia tốc kế là tín hiệu thực từ WISDM; phần hành vi-sinh lý được mô phỏng có kiểm soát để kiểm chứng context-aware.

Nguyên tắc suy luận công thức Module 2

Cách hiểu đúng: các công thức là *evidence-based heuristic mapping*, không phải công thức y sinh lấy nguyên văn từ một paper.

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

Paper cung cấp	Khóa luận suy luận
Cơ chế tác động	Stress kích hoạt hệ giao cảm; thiếu ngủ làm tăng phản ứng stress; vận động có thể giảm stress.
Chiều ảnh hưởng	Biết biến nào tăng/giảm stress hoặc HR, ví dụ workload tăng stress, outdoor/social có xu hướng phục hồi.
Khoảng hợp lý	Hệ số được chuẩn hóa về thang stress 1–9 và không để một biến đơn lẻ chi phối toàn bộ nhãn.

- Ví dụ $\Delta HR_{\text{stress}} = (S - 4) \times 3$: paper không cho “3 bpm/level”; hệ số được chọn để stress rất cao chỉ cộng tối đa khoảng 15 bpm.
- HR do stress vì vậy nhỏ hơn tác động vận động mạnh như Jogging (+40 bpm).

Câu trả lời khi bị hỏi: Paper neo cơ chế/biên hợp lý; hệ số là tham số mô phỏng rule-based, minh bạch và có thể học từ dữ liệu thật sau này.

Mô phỏng Screen Usage, Mood và Energy

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

Screen_Usage_Current

Mood_Score

Energy_Level

$$U(t) = B_{\text{act}}(a_t) M_{\text{loc}}(l_t) [1 + (M(t) - 0.15)(d) + \Delta M_{\text{time}} + \Delta M_{\text{act}}(d) + \Delta M_{\text{clip}}((57 + 4)0.3 + (d) \cdot$$

$$M_0(d) = 5 + F_{\text{mood}}(d) \times 3$$

- Activity quyết định khả năng dùng điện thoại.
- Location điều chỉnh theo bối cảnh.
- Stress chỉ tăng nhẹ, không chi phối toàn bộ feature.
- Mood nền dao động theo ngày/sự kiện.
- Stress cao kéo mood xuống vừa phải.
- Biên tiềm ẩn về phục hồi/fatigue.
- Bị ảnh hưởng bởi chu kỳ, mệt mỗi tuần và sự kiện.

Nguồn neo: Mobile sensing, MoodScope và StudentLife hỗ trợ liên hệ giữa phone usage, mood, sleep, activity; các hệ số vẫn là heuristic chuẩn hóa, không phải công thức lâm sàng.

Mô hình hóa nhịp tim theo bối cảnh

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

$$HR(t) = HR_{\text{rest}} + \Delta HR_{\text{activity}} + \Delta HR_{\text{stress}} + \Delta HR_{\text{fatigue}} + \varepsilon$$

- $HR_{\text{max}} = 208 - 0.7 \times \text{Age}$: neo theo Tanaka et al. (2001); HR_{rest} lấy từ hồ sơ người dùng.
- $\Delta HR_{\text{activity}}$: quy đổi thực dụng từ MET (Ainsworth, 2011)
 - Sitting: +0 bpm | Walking: +18 bpm | Jogging: **+40 bpm**
- $\Delta HR_{\text{stress}} = (\text{StressLevel} - 4) \times 3 \text{ bpm}$ — heuristic từ cơ chế hệ giao cảm.
- $\Delta HR_{\text{fatigue}} = (1 - E) \times 5 \text{ bpm}$ — correction nhỏ khi phục hồi kém.

Ý nghĩa: HR không đặc hiệu cho stress; hệ số stress tối đa khoảng +15 bpm để không lẫn át vận động mạnh như Jogging.

Công thức stress đa yếu tố

$$S_{\text{base}}(t) = S_0 + \Delta S_{\text{time}} + \Delta S_{\text{activity}} + \Delta S_{\text{location}} \\ + \Delta S_{\text{work}} + \Delta S_{\text{HR}} + \Delta S_{\text{sleep}} + \Delta S_{\text{momentum}}$$

Cơ sở lý thuyết:

- ΔS_{time} : nhịp cortisol (Chrousos, 2009)
- $\Delta S_{\text{activity}}$: endorphin khi vận động (Salmon, 2001)
- $\Delta S_{\text{location}}$: mô hình Demand-Control (Karasek, 1979)

Tính quán tính stress:

- ΔS_{sleep} : ngủ kém / phục hồi kém → tăng stress (McEwen, Yoo)
- $\Delta S_{\text{momentum}} = (\bar{S}_{\text{recent}} - 4) \times 0.3$
- Allostatic load: stress tích lũy theo thời gian

Điểm quan trọng: Các ΔS là modifier chuẩn hóa cho thang 1–9; nguồn nghiên cứu hỗ trợ cơ chế/chiều tác động, còn hệ số là heuristic có kiểm soát.

Context-Stress Modifier — Đóng góp cốt lõi

Đặt vấn đề và
mục tiêu
nghiên cứuPhương pháp
đề xuấtThực nghiệm
và kết quảĐóng góp, hạn
chế và hướng
phát triển

Kết luận

$$S_{\text{modified}}(t) = S_{\text{base}}(t) + \delta(a, l, c) \times A_{\text{sleep}} + \delta_{\text{env}} + \delta_{\text{social}} + \varepsilon$$

Ý tưởng then chốt (Lazarus & Folkman, 1984): *Cùng một tín hiệu sinh lý, ý nghĩa stress hoàn toàn khác nhau tùy ngữ cảnh.*

Tình huống	HR	δ	Diễn giải stress
Sitting + Work + chiều + deadline	95 bpm	+2.0	Stress rất cao
Jogging + Outdoor + sáng cuối tuần	140 bpm	-1.5	Stress thấp
Walking + Commute + sáng ngày thường	100 bpm	+0.8	Stress nhẹ
Sitting + Home + tối + nghỉ ngơi	68 bpm	-1.5	Thư giãn

Lưu ý: $\delta(a, l, c)$ là lookup heuristic có neo Lazarus–Folkman/context-aware stress detection; A_{sleep} khuếch đại nhẹ khi bối cảnh đã gây stress.

Pipeline chống rò rỉ dữ liệu

Nguyên tắc bắt buộc cho chuỗi thời gian:

Split → Encode → Normalize → Sequence

- Chia dữ liệu **theo thứ tự thời gian** 70/15/15 (không shuffle).
- Fit encoder/scaler **chỉ trên train**; transform cho val/test.
- Tạo sequence 60 bước $\times$ 13 đặc trưng → dự đoán stress bước kế tiếp.

Bài học thực tế từ nghiên cứu:

- Thử nghiệm 17 đặc trưng kỹ thuật (rolling features) $\Rightarrow$ **training loss = 10.23** thay vì 0.92
- **Nguyên nhân:** rolling window rò rỉ thông tin tương lai $\rightarrow$ data leakage
- **Giải pháp:** loại bỏ rolling features, giữ 13 đặc trưng “sạch”

Thiết lập thực nghiệm

Môi trường:

- CPU Intel Core, 16GB RAM
- Python 3.12.4
- TensorFlow 2.16.1
- scikit-learn, SHAP, Keras Tuner

Nguyên tắc công bằng:

- Cùng dữ liệu, cùng pipeline
- Cùng callbacks, batch size
- Cùng protocol đánh giá
- Seed cố định (42)

Metrics: MAE, RMSE, R^2 cho bài toán hồi quy | Accuracy, F1 cho HAR

Stress Baseline: Bi-LSTM chưa tối ưu

Kiến trúc baseline: Stacked Bi-LSTM, dropout = 0.3, lr = 0.001, 320K tham số.

Kết quả baseline:

- $R^2 = 0.9245$ (giải thích 92.5%)
- $MAE = 0.6855$
- $RMSE = 0.8723$
- Tổng 320,129 tham số

⇒ *Tốt nhưng còn dư địa cải thiện*

Chẩn đoán:

- Dropout = 0.3 quá lớn → underfitting
- Learning rate = 0.001 → hội tụ chậm
- 320K params → over-parameterized

⇒ *Cần Bayesian Optimization*

Câu hỏi: Có thể cải thiện đáng kể chỉ bằng tuning mà không đổi kiến trúc?

Bayesian Optimization: cải thiện rõ rệt

Metric	Baseline	Tuned	Cải thiện
MAE	0.686	0.529	−22.8%
RMSE	0.872	0.748	−14.2%
R^2	0.924	0.944	+2.2%
Tổng params	320K	164K	−48.9%

Thay đổi quan trọng nhất:

- Dropout: 0.3 → **0.1** — giải phóng năng lực biểu diễn
- Learning rate: 0.001 → **0.01** — thoát local minima nhanh hơn
- LSTM units lớp 1: 128 → **64** — mô hình “gọn hơn mà khỏe hơn”

Insight: Mô hình nhỏ hơn 49% nhưng MAE thấp hơn 22.8% ⇒ baseline bị *over-parameterized*

So sánh 5 mô hình trên cùng điều kiện

[Họ và tên
sinh viên]


Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận



Kết quả: Bi-LSTM Tuned đạt $R^2 = 0.956$, **MAE = 0.441** — tốt nhất trong thiết lập semi-synthetic.

MLP ($R^2 = 0.833$) vs Simple LSTM ($R^2 = 0.943$): temporal dependency đóng góp $\sim 11\%$ R^2 .

Bài học quan trọng nhất từ so sánh mô hình

“Tối ưu siêu tham số quan trọng hơn thay đổi kiến trúc”

Bằng chứng: cùng kiến trúc Stacked Bi-LSTM, chỉ khác hyperparameters:

	Bi-LSTM Baseline	Bi-LSTM Tuned	Cải thiện
MAE	0.716	0.441	−38.4%
R^2	0.907	0.956	+5.4%
Params	320K	164K	−48.9%

Phát hiện bất ngờ: Simple LSTM 1 lớp ($R^2 = 0.943$) *tốt hơn* Bi-LSTM Baseline ($R^2 = 0.907$) — vì baseline bị over-parameterized + underfitting. Sau tuning, Bi-LSTM mới thể hiện đúng tiềm năng.

Ý nghĩa: Kiến trúc tốt + siêu tham số xấu < Kiến trúc đơn giản + siêu tham số phù hợp

Phân tích lỗi: tuned cải thiện ở nơi quan trọng nhất

[Họ và tên
sinh viên]


Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận



Cải thiện theo mức stress:

- Very High (8–9): **−46.1% MAE**
- Medium (4–5): **−14.1% MAE**
- Sitting: **−31.2% MAE**


Tổng thể:

- 82.7% dự đoán sai < 1 điểm
- Median AE: 0.547 → **0.340**
- Bias: +0.295 → **−0.150**

Feature importance: 4 phương pháp đồng thuận

[Họ và tên
sinh viên]Đặt vấn đề và
mục tiêu
nghiên cứuPhương pháp
đề xuấtThực nghiệm
và kết quảĐóng góp, hạn
chế và hướng
phát triển

Kết luận



2 đặc trưng nhất quán top-2: Mood_Score (hạng TB: 1.75) và Heart_Rate (hạng TB: 2.25)

Hành vi smartphone (Screen_Usage, Phone_Event) cũng đóng vai trò quan trọng — gợi mở digital phenotyping.

So sánh thứ hạng đặc trưng giữa các phương pháp

[Họ và tên
sinh viên]


Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận



Insight: Location hạng 1 ở RF nhưng hạng 8 ở Permutation/SHAP — vì Decision Tree khai thác biến categorical tốt, còn LSTM nắm bắt interaction phức tạp hơn. Tổng hợp hạng (rank aggregation) giúp giảm thiên lệch từ phương pháp đơn lẻ.

Tổng hợp kết quả theo câu hỏi nghiên cứu

- **RQ1 — Context-aware:** Mô hình học theo *tổ hợp ngữ cảnh* (5 đặc trưng ngữ cảnh/hành vi trong top-8), không dựa vào sinh lý đơn biến. ✓
- **RQ2 — Chuỗi vs phi chuỗi:** MLP $R^2 = 0.833$ vs Simple LSTM $R^2 = 0.943 \Rightarrow$ phụ thuộc thời gian đóng góp $\sim 11\%$ R^2 . ✓
- **RQ3 — Bayesian Optimization:** Cùng Bi-LSTM: MAE -38.4% , params -48.9% . **Tuning > thay kiến trúc.** ✓
- **RQ4 — Đặc trưng cốt lõi:** Mood_Score + Heart_Rate nhất quán top-2 ở cả 4 phương pháp. Nhóm sinh lý-hành vi-ngữ cảnh là *cốt lõi*. ✓

4/4 câu hỏi nghiên cứu đều có bằng chứng thực nghiệm trả lời.

Tóm tắt kết quả sau thực nghiệm

3 kết quả chính

$$R^2 = 0.956$$

Kết quả tốt nhất
trong bộ dữ liệu
semi-synthetic

–46.1% MAE

Cải thiện mạnh nhất
ở nhóm stress rất cao
trong tập kiểm thử

–48.9% params

Mô hình nhỏ hơn
nhưng sai số thấp hơn
nhờ Bayesian
Optimization

“Tối ưu siêu tham số quan trọng hơn thay đổi kiến trúc”
– Bài học cốt lõi trong phạm vi thực nghiệm của khóa luận

Đóng góp phương pháp theo 3 tầng

① Tầng bài toán:

Chuyển từ phân loại stress rời rạc → **hồi quy liên tục (1–9)** — biểu diễn cường độ mịn hơn, phù hợp cảnh báo sớm.

② Tầng dữ liệu và phương pháp:

Xây dựng bộ dữ liệu bán mô phỏng đa phương thức có thể truy vết; đề xuất **Context-Stress Modifier** dựa trên bộ ba (hoạt động $\times$ vị trí $\times$ thời gian) để xử lý nhập nhằng sinh lý.

③ Tầng bằng chứng:

Benchmark **5 kiến trúc** + **4 phương pháp** giải thích + phân tích lỗi đa chiều (theo stress/hoạt động/thời gian). Chuỗi lập luận khép kín: RQ → phương pháp → bằng chứng → kết luận.

Giới hạn phạm vi đóng góp: Đây là khung phương pháp/proof-of-concept, chưa phải hệ thống stress đạt chuẩn lâm sàng.

Hạn chế nghiên cứu (khung validity)

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

- **Construct validity:** Nhãn stress bán mô phỏng, chưa phải nhãn lâm sàng/EMA đo trực tiếp. R^2 cao phản ánh một phần tính nhất quán của bộ sinh dữ liệu.
- **Modeling validity:** Hệ số công thức là heuristic có neo nghiên cứu; chưa được học/hiệu chỉnh từ dữ liệu stress thực địa.
- **Internal validity:** Pipeline chống leakage đầy đủ, nhưng chưa có ablation test cho từng thành phần Context-Stress Modifier.
- **External validity:** Chưa kiểm chứng trên dữ liệu thực địa đa đối tượng (khác giới, tuổi, nghề).
- **Conclusion validity:** Cần bổ sung kiểm định thống kê (paired test, bootstrap CI) qua nhiều lần chạy.

Trình bày hạn chế giúp xác định đúng phạm vi: kết quả hiện là proof-of-concept cần external validation.

Ngắn hạn (3–6 tháng):

- Thu thập dữ liệu thực tế smartphone/wearable kết hợp EMA.
- Học/hiệu chỉnh hệ số công thức từ dữ liệu thật thay vì giữ toàn bộ rule-based.
- Mở rộng benchmark: Transformer, Temporal Convolutional Networks.
- Thí nghiệm ablation: bật/tắt Context-Stress Modifier.

Trung hạn (6–18 tháng):

- Triển khai suy luận gần real-time trên mobile.
- Cá nhân hóa mô hình (transfer learning / meta-learning).
- Federated Learning cho bảo mật dữ liệu sức khỏe.

Dài hạn:

- Mở rộng đa cảm biến sinh học (EDA, HRV, EEG).
- Predict-to-intervene: tự động đề xuất can thiệp dựa trên stress dự đoán.

Khóa luận đã xây dựng thành công:

- 1 **Hệ thống context-aware end-to-end** từ dữ liệu cảm biến đến dự đoán stress liên tục — đạt $R^2 = 0.956$ và $MAE = 0.441$ trong thiết lập semi-synthetic.
- 2 **Context-Stress Modifier** giải quyết trực tiếp vấn đề nhập nhằng sinh lý — cùng HR nhưng ý nghĩa khác biệt tùy bối cảnh.
- 3 **Bài học thực nghiệm:** Tuning cải thiện 38.4% MAE — cho thấy *siêu tham số phù hợp có thể quan trọng hơn chỉ tăng độ phức tạp kiến trúc*.

Giá trị cốt lõi: Khung sinh dữ liệu và dự đoán stress minh bạch, có thể truy vết, sẵn sàng để kiểm chứng bằng dữ liệu thực.

Xin cảm ơn Hội đồng!

[Họ và tên
sinh viên]

Đặt vấn đề và
mục tiêu
nghiên cứu

Phương pháp
đề xuất

Thực nghiệm
và kết quả

Đóng góp, hạn
chế và hướng
phát triển

Kết luận

Cảm ơn thầy cô và các bạn!

Em sẵn sàng trao đổi về: cơ sở hệ số heuristic, thiết kế Context-Stress Modifier, tính hợp lệ của dữ liệu bán mô phỏng, và kế hoạch kiểm chứng thực địa.